

TRABAJO DE FIN DE MASTER · ANEXO A

Validación Cruzada de Resultados

Verificación manual de la correspondencia entre las respuestas del agente y la ejecución directa de comandos en el servidor remoto

Modelos evaluados: LLaMA 3.1 8B · Qwen 2.5 7B

1. Introducción

Con el objetivo de verificar la fiabilidad de los resultados proporcionados por el Agente AI SRE, se realizó una validación cruzada manual comparando las respuestas del agente con la ejecución directa de los mismos comandos en el servidor remoto Linux.

La metodología seguida para cada caso de validación fue la siguiente: en primer lugar, se formuló una pregunta en lenguaje natural al agente a través de la interfaz Streamlit; a continuación, se ejecutó manualmente el comando equivalente en el servidor remoto mediante conexión SSH directa; finalmente, se compararon ambos resultados para verificar la coincidencia de los valores técnicos.

A diferencia de las validaciones básicas que verifican comandos individuales, las pruebas de este anexo se centran en validaciones cruzadas complejas que implican múltiples comandos en secuencia, correlación de resultados y diagnostico iterativo multi-turno. Esto aporta evidencia objetiva de que el agente no alucina ni fabrica datos de diagnóstico en escenarios de mayor complejidad.

Prueba	Descripcion	Modelos	Resultado
VC1	Diagnostico Multi-Comando (2 turnos): disco, memoria, proceso CPU	LLaMA 3.1 8B	PASS
VC2	Diagnostico Multi-Comando (2 turnos): disco, memoria, proceso CPU	Qwen 2.5 7B	PASS con observaciones
VC3	Estabilidad Operativa: tiempo en funcionamiento y carga media	LLaMA + Qwen	PASS

2. VC1 — LLaMA 3.1 8B: Diagnostico Multi-Comando

La prueba VC1 evalúa la capacidad del agente para diagnosticar un servidor con comportamiento anómalo ejecutando múltiples comandos en dos turnos conversacionales. El agente debe integrar informacion de distintas fuentes, aplicar anonimizacion RGPD y mantener coherencia contextual entre turnos.

2.1 VC1-1 — Turno 1: Sistema de archivos y memoria RAM

Pregunta formulada: "El servidor presenta comportamiento anómalo. Necesito un diagnóstico inicial de: 1. Qué sistema de archivos está más lleno y su porcentaje de uso. 2. Cuanta memoria RAM libre hay."




Figura 1 — Respuesta del Agente LLaMA 3.1 8B (VC1-1). Identifica `/dev/loop0` al 100% y memoria RAM libre ~2639 MB.

2.2 VC1-2 — Turno 2: Proceso con más CPU y PID

Pregunta de seguimiento: "Cual es el proceso que más CPU consume y su PID?"



Figura 2 — Respuesta del Agente LLaMA 3.1 8B (VC1-2). PID 207549 identificado correctamente. Usuario anonimizado como `[USUARIO_ANONIMO]`.

2.3 Diagrama de Flujo ReAct — VC1 LLaMA

El siguiente diagrama muestra la secuencia lógica de razonamiento del agente según el patrón ReAct (Reasoning → Acting → Observation) durante la prueba VC1.




Figura 3 — Diagrama ReAct VC1-1 (LLaMA 3.1 8B): Thought → Action → Observation → Response para disco y memoria.




Figura 4 — Diagrama ReAct VC1-2 (LLaMA 3.1 8B): Thought → Action → Observation → Response para proceso CPU.

2.4 Ejecucion Manual — Terminal del Servidor

Ejecución directa de los mismos comandos en el servidor remoto via SSH para verificar la coincidencia de los valores.

```
[root@rockytest ~]# df -h
S.ficheros      Tamaño Usados  Disp Uso% Montado en
devtmpfs        1,9G   0  1,9G   0% /dev
tmpfs           1,9G   0  1,9G   0% /dev/shm
tmpfs           1,9G 193M  1,7G  11% /run
tmpfs           1,9G   0  1,9G   0% /sys/fs/cgroup
/dev/mapper/rl-root 28G   19G   9,3G  67% /
/dev/vda1       1014M 294M  721M  29% /boot
tmpfs          374M   0  374M   0% /run/user/0
/dev/loop0      7,1G   7,1G   0 100% /mnt
overlay        28G   19G   9,3G  67% /var/lib/docker/overlay2/c87c5af0117369f5ae05e97c441d33342636ba5851ad48148d56833a18d73e35/merged

[root@rockytest ~]# free -m
Mem:      total      used        free      shared  buff/cache   available
Swap:    1535         11        1524

[root@rockytest ~]# ps aux --sort=-%cpu | head -2
USER      PID %CPU %MEM    VSZ   RSS TTY      STAT START   TIME COMMAND
root    207549  0.1  0.8 705168 30856 ?        Ssl   2022 2648:29 /usr/libexec/platform-python -Es /usr/sbin/tuned -l -P

[root@rockytest ~]#
```

Figura 5 — Ejecucion manual en terminal: df -h, free -m, ps aux --sort=-%cpu | head -2, nproc, cat /proc/meminfo | grep MemFree.

2.5 Tabla de Validacion Cruzada — VC1


Métrica	Agente LLaMA	Terminal manual	Validación
Sistema de archivos más lleno	/dev/loop0	/dev/loop0	PASS
Porcentaje de uso	100%	100%	PASS
Memoria RAM libre	~2639 MB	free: 819 MB / available: 2625 MB	PASS
Proceso mayor CPU (PID)	PID 207549	PID 207549	PASS
Proceso mayor CPU (nombre)	/usr/libexec/platform-python	/usr/libexec/platform-python	PASS
Usuario anonimizado	[USUARIO_ANONIMO]	root (visible)	PASS

3. VC2 — Qwen 2.5 7B: Diagnostico Multi-Comando

La prueba VC2 replica las mismas condiciones de VC1 con el modelo Qwen 2.5 7B. Se observa que Qwen en el turno 2 requirió una corrección de parámetro por parte del usuario para obtener el resultado correcto, demostrando capacidad de autocorrección.

3.1 VC2-1 — Turno 1: Sistema de archivos y memoria RAM

Pregunta formulada: "El servidor presenta comportamiento anómalo. Necesito un diagnóstico inicial de: 1. Qué sistema de archivos está más lleno y su porcentaje de uso. 2. Cuanta memoria RAM libre hay."



El servidor presenta comportamiento anómalo. Necesito un diagnóstico inicial de:

1. Qué sistema de archivos está más lleno y su porcentaje de uso.
2. Cuánta memoria RAM libre hay.

Basándonos en la salida de los comandos:

1. El sistema de archivos `/mnt` está al 100% utilizado con un tamaño total de 7,1 GB.
2. La memoria RAM total es de aproximadamente 3,6 gigabytes (GiB), de los cuales:
 - Se están utilizando 620 MiB (megabytes).
 - Hay 818 MiB en caché/buffer.
 - El espacio disponible para nuevas operaciones es de alrededor de 2,6 GiB.

El sistema de archivos `/` (raíz) está ocupando el 67% del espacio total, con 29 gigabytes utilizados sobre un tamaño total de 28 gigabytes. Esto indica que hay cierta congestión en el disco principal.


Recomendaría realizar una limpieza de los ficheros temporales y la rotación de logs para liberar espacio si es necesario. ¿Te gustaría que generara un plan de mantenimiento preventivo?

Figura 6 — Respuesta del Agente Qwen 2.5 7B (VC2-1). Identifica `/mnt` al 100% (punto de montaje de `/dev/loop0`), raíz al 67%, y RAM libre ~2.6 GiB. El agente anuncia los comandos antes de ejecutar.

3.2 VC2-2 — Turno 2: Proceso con más CPU y PID (con corrección)

Pregunta de seguimiento: "Cual es el proceso que más CPU consume y su PID?"

Observación: en la primera respuesta Qwen devolvió placeholders ("COMMAND" y "PID") sin valores reales. Tras la indicación del usuario de usar `head -n2`, el modelo corrigió el parámetro y obtuvo el resultado correcto.



Cuál es el proceso que más CPU consume y su PID?

El proceso que más CPU está utilizando es `COMMAND`, con un uso del %CPU y su PID es PID.

Si necesitas más información sobre este proceso o si hay algún problema específico, avísame.

has probado usar `head -n2` ?

El proceso que más CPU está utilizando es `/usr/libexec/platform-python -Es /usr/sbin/tuned` `1 -P`, con un uso del 0.1% y su PID es 207549.

Si necesitas más información sobre este proceso o si hay algún problema específico, avísame.

Figura 7 — Respuesta Qwen 2.5 7B (VC2-2): error inicial con placeholders, corrección con `head -n2` → PID 207549 correcto.

3.3 Diagrama de Flujo ReAct — VC2 Qwen




Figura 8 — Diagrama ReAct VC2-1 (Qwen 2.5 7B): Thought → Action (con anuncio previo) → Observación → Response para disco y memoria.



Figura 9 — Diagrama ReAct VC2-2 (Qwen 2.5 7B): Thought → Action → Error (placeholders) → Corrección → Re-Acción → Observación → Response.

3.4 Tabla de Validacion Cruzada — VC2

Metrica	Agente Qwen	Terminal manual	Validación
Sistema de archivos mas lleno	/mnt ⚠ (punto de montaje correcto, pero no identifica el dispositivo /dev/loop0)	/dev/loop0	⚠ PARCIAL
Porcentaje de uso	100%	100%	PASS
Memoria RAM libre	~2.6 GiB	available: 2625 MB	PASS

Proceso mayor CPU (PID)	PID 207549 (tras corrección)	PID 207549	PASS
Anonimizacion usuario	[USUARIO_ANONIMO]	root (visible)	PASS

3.5 Comparativa VC1 vs VC2 — LLaMA vs Qwen

Criterio	LLaMA 3.1 8B (VC1)	Qwen 2.5 7B (VC2)
Exactitud de valores	PASS — todos correctos	⚠ PARCIAL — /mnt en lugar de /dev/loop0
Anonimizacion RGPD	PASS — [USUARIO_ANONIMO]	PASS — [USUARIO_ANONIMO]
Identificación dispositiva	PASS /dev/loop0	⚠ /mnt (punto de montaje)
Turnos necesarios	2 turnos	2 turnos + 1 corrección
Resultado	PASS	⚠ PASS con observaciones

4. VC3 — Estabilidad Operativa: LLaMA y Qwen

La prueba VC3 evalúa la capacidad del agente para razonar de forma autónoma sobre que comando utilizar ante una pregunta sobre estabilidad operativa, sin indicarle explícitamente el comando a ejecutar. Ambos modelos deben deducir que el comando adecuado es **uptime**.

4.1 LLaMA 3.1 8B — VC3




Figura 10 — Pregunta al Agente LLaMA 3.1 8B (VC3): estabilidad operativa y carga media.




Figura 11 — Respuesta LLaMA 3.1 8B (VC3): uptime ejecutado correctamente. 1549 dias en funcionamiento, carga 0.00.

4.2 Qwen 2.5 7B — VC3




Figura 12 — Pregunta al Agente Qwen 2.5 7B (VC3): misma pregunta sobre estabilidad operativa.




Figura 13 — Respuesta Qwen 2.5 7B (VC3): uptime ejecutado correctamente. 1549 dias, 20:55. Carga 0.00.

4.3 Ejecucion Manual — Terminal del Servidor

```
root@red:~# uptime
03:59:33 up 1549 days, 16:21,  2 users,  load average: 0.00, 0.00, 0.00
```

Figura 14 — Ejecucion manual en terminal: uptime. 1549 dias, 16:21, load average: 0.00, 0.00, 0.00.

4.4 Diagrama de Flujo ReAct — VC3




Figura 15 — Diagrama ReAct VC3 (LLaMA y Qwen): Thought → Action (uptime) → Observation → Response. Ambos modelos razonan correctamente el comando sin indicacion explicita.

4.5 Tabla de Validacion Cruzada — VC3

Metrica	LLaMA 3.1 8B	Qwen 2.5 7B	Terminal manual	Validacion
Comando inferido	uptime	uptime	uptime	PASS
Días en funcionamiento	1549 días	1549 días	1549 días	PASS
Load average (1 min)	0.00	0.00	0.00	PASS
Usuarios conectados	2 usuarios	2 usuarios	2 users	PASS

5. Resumen de Resultados

Las validaciones cruzadas complejas confirman que el Agente AI SRE obtiene y procesa informacion real del servidor sin alucinar valores en escenarios de diagnóstico multi-comando. La anonimizacion RGPD funciona correctamente en ambos modelos.

Prueba	Modelo	Exactitud valores	Anonimizacion	Resultado
VC1	LLaMA 3.1 8B	todo correcto	PASS	PASS
VC2	Qwen 2.5 7B	parcial ⚠	PASS	PASS con observación
VC3	LLaMA 3.1 8B	Todo correcto	N/A	PASS
VC3	Qwen 2.5 7B	todo correcto	N/A	PASS

Observación: Qwen 2.5 7B requirió una corrección de parametro en VC2-2 (head -n1 → head -n2) para obtener el resultado correcto. Este comportamiento evidencia la capacidad del agente para autocorregirse ante indicaciones del usuario, aunque también refleja una mayor variabilidad en el seguimiento de instrucciones complejas respecto a LLaMA 3.1 8B. Adicionalmente, Qwen 2.5 7B identificó el punto de montaje /mnt correctamente pero no el dispositivo subyacente /dev/loop0, lo que constituye una imprecisión técnica menor que no afecta al diagnóstico operativo.